




Analítica de la Web

PhD.(c) Junior Fabian Arteaga





Definiendo las Reglas del Curso (Sílabo)





Un poco de Historia...

1957

Agencia de Proyectos
de Investigaciones
avanzadas (ARPA)



1967

Hombre llega a la
luna.

Marca el inicio de las
comunicaciones
globales.



1969

ARPA partiendo de las experiencias y conocimientos en el campo de las tecnologías de redes, crea **ARPAnet**



1990

ARPAnet se desmantela y aparecen :

- ☐ **MILNET**: caracter militar.
- ☐ **INTERNET**: naturaleza publica, orientada al mundo académico, científico e industrial.






Internet

“Internet es una red de computadoras, formada a su vez por muchas redes independientes, que se pueden comunicar unas con otras, intercambiar mensajes y compartir información en forma de archivos”

1991

Tim Berners Lee, crea la **Word Wide Web** mas conocida como **WWW**.



Propuso un nuevo sistema de **"hipertexto"** para compartir documentos.

HyperText Markup Language
(Lenguaje de Marcas de Hipertexto)

Protocolos de internet: http, html

- ❑ **Http:** Protocolo de transferencia de hipertexto (HyperText Transfer Protocol)
- ❑ **Html:**
 - ❑ Un formato hipertextual y hipergráfico para publicar documentos en la red.
 - ❑ Creado para codificar y visualizar documentos.
 - ❑ Incluye formatos, layout y estructura de un documento web.




```

Welcome to my web site! [www/index.html] - Dreamweaver
File Edit View Insert Modify Text Commands Site Window Help
Title: Welcome to my web site!
<p align=center><font size="5" color="#800000">
  <b>Welcome
  </b>
</font>
<font size="5">
  to my new web site!
</font>
<blockquote>
  <p>It's still under construction, but that doesn't mean that
  it's not worth exploring. I update this page regularly, so
  make sure to bookmark it if you like what you see.
  <p>Look around, have fun, and thanks for visiting!
</p>
</blockquote>

```



Página Web



HTML

```
287         <div class="nota-contenido left sp
288         <div class="bajada-nota">
289             <p>         <a href="http://el
290 <a href="http://elcomercio.pe/tag/275843/c
291 >blog/</a></p>
292         </div>
293         <div class="meta">
294             Sábado 07 de abril de 2012 - 0
295             <div class=
296 title="Silvio Rodríguez recibió a Camila V.
297 <div class="detalle-player">Luis Lobos,
298
299             <div id="te:
300 vallejo"target="_blank" >Camila Vallejo</a>
301 rodriguez"target="_blank" >Silvio Rodrigue
302
303         <p><a href="http://elcomercio.pe/t
304 Chile (JJCC), Karol Cariola, a Luis Lobos :
305 fundados por él en La Habana. </p>
306
307         <p>El músico, una de las principal
308 href="http://segundacita.blogspot.com/"tar
309
310         <p>Vallejo viajó a la isla como pa
311 4 de abril. En tanto, ha sido profundament
312
313         <p>Durante su estancia en Cuba, lo
314 class="20120407"></span>
315         <div class="seo-nota">
316             <h2 ><a href="/tag
317 Rodríguez</a></h2><span class="coma">,</sp
318
319         <div class="related-se
320             <div><span class="
321 obedecio-al-regimen-cubano">Yoani Sánchez:
322 href="http://elcomercio.pe/mundo/1397945/n
323 con otra bloguera cubana</a></h3></div><di
324 rindio-homenaje-su-blog-facundo-cabral">Si
325 href="http://elcomercio.pe/mundo/1397509/n
326 uno de los líderes más importantes del mund
```

Web 1.0








Web 1.0	Web 2.0	
DoubleClick	<u>Google AdSense</u>	(Servicios Publicidad)
Ofoto	<u>Flickr</u>	(Comunidades fotográficas)
Akamai	<u>BitTorrent</u>	(Distribución de contenidos)
mp3.com	<u>Napster</u>	(Descargas de música)
Britannica Online	<u>Wikipedia</u>	(Enciclopedias)
Sitios personales	<u>Blogs</u>	(Páginas personales)
Especulación con dominios	<u>Optimización en motores de búsqueda</u>	(Búsqueda en la web)
Page views	<u>Cost per click</u>	(Sitios visitados)
CMSs	<u>Wikis</u>	(Manejo de contenidos)

VERSIÓN	TIPO DE WEB	TECNOLOGÍAS	CARACTERÍSTICAS
Web 1.0 "La web"	Estática.	HTML, GIF.	- Las páginas web son documentos estáticos que casi nunca se actualizan.
Web 2.0 "Web Social"	Dinámica Colaborativa	DHTML, ASP, CSS, AJAX, DHTML, XML.	- Las páginas web son construidas dinámicamente a partir de una o varias bases de datos. - Los usuarios se convierten en contribuidores. Publican la información y realizan cambios en los datos.
Web 3.0 "Web Semántica"	Estructurada con significados bien definidos	RDF, OWL, JENA, SESAME, SPARQL, etc.	- Basada en la representación del significado y conexión del conocimiento, - Añade metadatos semánticos a la información de la web a través de la utilización de ontologías. - Amplia la interoperabilidad entre los sistemas informáticos. - Reduce la mediación de operadores humanos necesaria. - Creación colectiva y colaborativa de los recursos.
Web 4.0 "Web Ubicua"	Conexión Inteligente	Algoritmos de Procesamiento de Lenguaje natural.	- Desarrollo de Agentes personales inteligentes. - Desarrollo de Comunidades Semánticas. - Las aplicaciones de web ubicua podrán identificar recursos y gestionarlos dentro del contexto de sesiones temporales o duraderas.



Crecimiento de los datos en la Web

2013



Every 60 seconds



98,000+ tweets



695,000 status updates



11million instant messages



698,445 Google searches



168 million+ emails sent



1,820TB of data created



217 new mobile web users



Cada minuto del día en Internet pasa lo siguiente...



- 840 nuevos usuarios en las redes sociales
- 455 000 Tweets por minuto
- 400 horas de vídeo en YouTube
 - ◆ 4 146 600 reproducciones
- 46 740 millones posts en Instagram



→ Facebook:

- ◆ (2011) 650 000 posts
- ◆ (2016) 3 millones posts
- ◆ 510 000 comentarios
- ◆ 136 000 fotos subidas
- ◆ 293 000 estados
- ◆ 4 millones de likes



Like



Daily facebook data

>

**All US Academic
Libraries**

2 PBs vs. 30+ PBs







Empecemos desde 0...



→ 1 bit (posibles valores: 0 - 1)

→ 1 byte (8 bits)

◆ 256 combinaciones

◆ Es posible expresar cualquier carácter alfabético en 1 byte

◆ Hacer la prueba guardando un archivo de texto con una sola letra (ASCII, UTF-8)



→ 1 WORD

- ◆ Dependiendo del procesador (32, 64 bits)
- ◆ El procesador solo procesa palabras enteras, es decir por cada ciclo de reloj se procesa esa información



Symbol	Prefix	SI Meaning	Binary meaning	Size difference
k	kilo	$10^3 = 1000^1$	$2^{10} = 1024^1$	2.40%
M	mega	$10^6 = 1000^2$	$2^{20} = 1024^2$	4.86%
G	giga	$10^9 = 1000^3$	$2^{30} = 1024^3$	7.37%
T	tera	$10^{12} = 1000^4$	$2^{40} = 1024^4$	9.95%
P	peta	$10^{15} = 1000^5$	$2^{50} = 1024^5$	12.59%
E	exa	$10^{18} = 1000^6$	$2^{60} = 1024^6$	15.29%
Z	zetta	$10^{21} = 1000^7$	$2^{70} = 1024^7$	18.06%
Y	yotta	$10^{24} = 1000^8$	$2^{80} = 1024^8$	20.89%



→ Bytes...bits...

- ◆ Es muy común confundir 1 GB con 1 Gb
- ◆ En una casa con una conexión de 1Mbps:
 - 1 000 000 bits por segundo
 - $1\,000\,000 / 8 = 125\,000$ bytes por segundo
 - Velocidad real = 125 KB/s



→ Cada 5 minutos en internet se generan 1 exabyte de datos =
1,000,000,000,000,000,000 bytes

→ El gran acelerador de hadrones:

- ◆ Considerado el mayor invento de la humanidad, “el que podría ocasionar que el universo se colapse”
- ◆ Genera a través de sus sensores 500 exabytes de información =
500,000,000,000,000,000,000 byte




→ Y los gobiernos?

- ◆ El gobierno de Estados Unidos almacena la información de todos sus ciudadanos en el NSA (National Security Agency) de Utah en un data center con una capacidad de 5 Zettabytes

5,000,000,000,000,000,000,000 bytes



¿Por qué analizar la Web?



amazon.com

Recommended for You


Amazon.com has new recommendations for you based on [items](#) you purchased or told us you own.



[Google Apps Deciphered: Compute in the Cloud to Streamline Your Desktop](#)




[Google Apps Administrator Guide: A Private-Label Web Workspace](#)



[Googlepedia: The Ultimate Google Resource \(3rd Edition\)](#)

- 
- ▶ Domain
 - ▶ Sub-domain
 - ▶ Page URL
 - ▶ URL sub-directories
 - ▶ Page Meta Tags
 - ▶ Page Title
 - ▶ Page Content
 - ▶ Named Entities
 - ▶ Has Query
 - ▶ Referrer Query
 - ▶ Referring Domain
 - ▶ Referring URL
 - ▶ Outgoing URL
 - ▶ GeoIP Country
 - ▶ GeoIP State
 - ▶ GeoIP City
 - ▶ Absolute Date
 - ▶ Day of the Week
 - ▶ Day period
 - ▶ Hour of the day
 - ▶ User Agent
 - ▶ Zip Code
 - ▶ State
 - ▶ Income
 - ▶ Age
 - ▶ Gender
 - ▶ Country
 - ▶ Job Title
 - ▶ Job Industry

NYTimes (microtrends detection)





Market segmentation

Sentiment Analysis




Machine Learning

Google

Google Search

I'm Feeling Lucky

facebook





¿Cómo analizar la Web?

Programación

